

Exploration de la segmentation automatique par AssemblyNet pour la classification d'une maladie neurodégénérative

KISX8AFU - Initiation à la Recherche et Projet
Département EEA/IDS - Faculté des Sciences et Ingénierie

ASSIDAH Asma	22203679	Master 1 IdS Imagerie Médicale
MASSON Louis	22508017	Master 1 IdS Imagerie Médicale
ZIRN Léna	22504902	Master 1 IdS Imagerie Médicale

Ce travail a été supervisé par Mme. Noura Osman

Mai 2026

Résumé — Dans le cadre de notre Master 1 en Ingénierie de la Santé, et plus particulièrement en Imagerie Médicale, nous avons travaillé sur ce projet de recherche qui traite de la segmentation automatique des régions cérébrales par AssemblyNet basée sur le deep learning, pour la classification de l'atrophie multi-systématisée (AMS) à partir d'IRM T1. Nous avons extrait et analysé les volumes de 87 régions du cerveau sur la base de données de 100 sujets (50% de patients et 50% de contrôles). L'analyse a été faite à l'aide de méthodes de réduction de dimension, visualisation de distribution à l'aide de boxplots ainsi que de divers tests statistiques. Les résultats de ces analyses nous ont permis de mettre en évidence des différences significatives entre les deux groupes de sujets, particulièrement sur les régions déjà connues pour être touchées par l'AMS, comme le Putamen et le tronc cérébral. Ces caractéristiques ont ensuite été utilisées pour entraîner des modèles SVM. Plusieurs noyaux ont été testés, mais le noyau RBF s'est révélé être le plus performant en obtenant la meilleure classification en apparence. En revanche, la validation croisée de ce SVM a révélé une variabilité non négligeable, probablement due à un sur-apprentissage et au faible nombre de données sur lesquelles le modèle a été entraîné.

Abstract — In the context of our Master 1 in Health Engineering, and more specifically in Medical Imaging, we worked on this research project dealing with the automatic segmentation of brain regions using AssemblyNet based on deep learning, for the classification of Multiple System Atrophy (MSA) from T1 MRI. We extracted and analyzed the volumes of 87 brain regions from a database of 100 subjects (50% patients and 50% controls). The analysis was performed using dimensionality reduction methods, distribution visualization using boxplots, as well as various statistical tests. The results of these analyses allowed us to highlight significant differences between the two groups of subjects, particularly in regions already known to be affected by MSA, such as the Putamen and the brainstem. These features were then used to train SVM models. Several kernels were tested, but the RBF kernel proved to be the most effective, achieving the best classification performance at first glance. However, the cross-validation of this SVM revealed non-negligible variability, likely due to overfitting and the small amount of data on which the model was trained.

Glossaire — Imagerie par Résonance Magnétique (IRM), Atrophie Multi-Systématisée (AMS), Radial Basis Function (RBF), Convolutional Neural Network (CNN), Support Vector Machines (SVM), Analyse en Composante Principale (ACP) ou Principal Component Analysis (PCA), t-Distributed Stochastic Neighbor Embedding (t-SNE), Uniform Manifold Approximation and Projection (UMAP), Region Of Interest (ROI), Cross Validation (CV)

TABLE DES MATIÈRES

1 Introduction

2 Matériels et Méthodes

- 2.1 Données 3
- 2.2 Méthodes d'analyse 4
 - 2.2.1 Réduction de dimension 4
 - 2.2.2 Visualisation de distribution 4
 - 2.2.3 Tests statistiques 4
- 2.3 Entraînement SVM et évaluation 5

3 Résultats

- 3.1 Analyse exploratoire et statistique 6
 - 3.1.1 ACP 6
 - 3.1.2 Boxplots 6
 - 3.1.3 Tests Statistiques 7
- 3.2 Performance SVM et frontières de décision . . . 7

4 Discussion

5 Conclusion

I. INTRODUCTION

Notre sujet porte sur l'*exploration de la segmentation automatique par AssemblyNet pour la classification d'une maladie neurodégénérative* à l'aide de données d'IRM-T1. Commençons tout d'abord par apporter un peu de contexte avant de rentrer dans le vif du sujet.

L'IRM constitue une technique d'imagerie médicale non invasive qui permet d'imager de manière très détaillée des tissus mous et des organes. Celle-ci est alors très utile pour la détection d'anomalies telles que des tumeurs, des lésions vasculaires types AVC, ischémies ou encore des atteintes des tissus mous. Pour ce faire, on distingue de nombreux modes d'imagerie (nommés "séquence IRM") et parmi les principaux, on y trouve la pondération T1, la pondération T2 ainsi que la pondération en densité protonique. Ces séquences d'IRM se différencient par les temps de relaxation des protons d'hydrogène dans les tissus, qui influencent le contraste obtenu entre les différentes structures anatomiques.

Ainsi, comme notre travail porte sur la classification d'une maladie neurodégénérative, nous utiliserons des images pondérées en T1 car celles-ci permettent un contraste avantageux pour visualiser la matière blanche, ainsi que le liquide céphalo-rachidien (sombre). De cette manière, l'IRM se présente comme l'outil de référence pour l'exploration de maladies neurodégénératives. Parmi celles-ci, on retrouve les syndromes parkinsoniens

atypiques regroupant plusieurs entités dont l'atrophie multi-systématisée (AMS). L'AMS appartient aux synucléinopathies, pathologies définies par l'accumulation intracellulaire anormale de protéines α -nucléine, au même titre que la maladie de Parkinson idiopathique et la démence à corps de Lewy [1].

L'AMS induit une atrophie progressive notamment au niveau du Cervelet, du Putamen et du tronc cérébral. La similarité avec les autres synucléinopathies, sur le plan clinique et radiologique, complique le diagnostic différentiel, d'où la nécessité d'identifier des biomarqueurs d'imagerie quantitatifs pouvant servir simultanément au diagnostic, au pronostic et au suivi thérapeutique [2]. Pour cela, on utilise des données issues d'IRM pondérées en T1. Ce choix reste justifié d'un point de vue méthodologique : la pondération T1 maximise le contraste entre substance grise, substance blanche et liquide céphalo-rachidien, ce qui en fait le standard pour la morphométrie et la segmentation structurelle.

La segmentation est indispensable puisqu'il s'agit du processus de partitionnement d'une image en régions homogènes correspondant à des structures anatomiques distinctes, où chaque voxel reçoit une étiquette de classe. Deux approches sont comparées :

- **La segmentation classique** : Pour segmenter de cette manière, des atlas sont nécessaires, ils servent de carte de référence. Chaque atlas contient des régions d'intérêt déjà labellisées, il en existe une grande variété en neuro-imagerie. Dans le cadre de ce projet, l'utilisation de l'Atlas Hammers a été préférée pour la précision de ces régions labellisées ainsi que son utilisation fréquente dans les études d'imagerie IRM [3] afin d'être plus précis dans la mise en évidence de la maladie d'AMS. La segmentation produit un recalage spatial (transformation affine puis non-linéaire) d'un atlas anatomique de référence (Hammers) sur l'image individuelle, suivi du transfert des masques binaires de l'atlas vers l'espace du sujet. Les performances dépendent de la qualité du recalage ; l'adaptation reste limitée face à la variabilité inter-individuelle (taille, position, topologie des structures).
- **Segmentation automatique** : cette méthode de segmentation utilise des techniques de machine learning et deep learning afin d'extraire de manière automatisée des objets d'intérêt, et cela, sur la base d'algorithmes pré-entraînés à l'aide de segmentations réelles et manuelles. Le but est alors de s'appuyer sur ces segmentations existantes afin d'en créer une base de données sur laquelle on entraîne l'algorithme.

Dans le cadre de notre travail, nous utiliserons AssemblyNet. C'est une méthode de segmentation automatique de *deep learning* dont l'architecture se constitue d'un ensemble de CNN 3D pré-entraînés, organisés hiérarchiquement et votant collectivement pour attribuer une étiquette à chaque voxel. Le modèle apprend des représentations directement à partir de données annotées et s'adapte aux morphologies individuelles [4].

AssemblyNet sera alors exploré pour la suite des expérimentations.

À partir des segmentations, le volume de chaque région d'intérêt (ROI) est calculé :

$$V_{ROI} = N_{\text{voxels}} \times V_{\text{voxel}} \quad (1)$$

Ces volumes permettent alors de chercher les classes auxquelles appartiennent les sujets, et ce, avec des approches classiques de machine learning. De cette manière, les volumes constituent les caractéristiques d'entrée du classifieur. La base de données fournie (`data_volumes.xlsx`) contient les volumes de 87 structures cérébrales pour 100 sujets simulés à partir de profils de patients réels. Ainsi, nous avons à notre disposition 50 modèles de sujets contrôles et 50 modèles de patients d'AMS. Par ailleurs, les sujets de contrôle ont été générés synthétiquement tout en suivant la distribution de données réelles de sujets sains.

Pour traiter ces volumes, nous utiliserons des **Support Vector Machine** (SVM). Les SVM sont des algorithmes d'apprentissage supervisé recherchant l'hyperplan séparateur qui maximise la marge (ou distance) aux vecteurs support entre deux classes dans l'espace des caractéristiques. Pour les séparations non linéaires, le *kernel* projette les données dans un espace de plus grande dimension où la séparation linéaire est donc possible via une fonction noyau complexe (polynomiale, RBF).

Tout au long de ce rapport, nous étudierons alors l'application de la segmentation automatique par AssemblyNet dans le cadre de la classification de l'AMS. Puis, nous analyserons la distribution des volumes cérébraux entre sujets sains et patients à l'aide d'outils de visualisation (réduction de dimension et boxplot), mais aussi d'outils statistiques. Finalement, nous évaluerons la capacité discriminante d'un SVM sur les volumes tout en comparant différents noyaux.

II. MATÉRIELS ET MÉTHODES

Dans un premier temps, nous allons détailler l'ensemble des méthodes utilisées et expliciter les raisons qui nous ont poussés à les appliquer. Les résultats qui en découlent sont alors traités en partie III.

A. Données

L'étude repose sur une base de données de 100 sujets, répartis en deux groupes équilibrés avec 50 sujets contrôles (label 0), et 50 patients atteints d'AMS (label 1). Il s'agit de sujets **générés** à partir de profils statistiques de patients réels, qui reprennent des données cliniques d'origine.

En ce qui concerne les volumes des régions d'intérêt (ROI), ceux-ci sont en pourcentage. De cette manière, ils ont été normalisés au préalable par le volume intracrânien de chaque sujet. D'ailleurs, ces volumes correspondent aux volumes totaux des ROI (hémisphères gauche et droit) qui ont été calculés par **As-**

semblyNet à partir des images d'IRM pondérées en T1. Ils sont exprimés en pourcentage, ils sont donc déjà normalisés par le volume intracrânien de chaque sujet. De plus, les volumes correspondent aux volumes totaux, on ne fera pas la distinction entre les hémisphères droit et gauche. L'**Atlas Hammers** sera utilisé uniquement comme repère anatomique pour situer les volumes produits par AssemblyNet, via trois opérations : extraction des masques binaires, calcul des volumes correspondants et identification des régions communes aux deux approches.

B. Méthodes d'analyse

Dans un premier temps, il a été important d'effectuer une analyse concernant la répartition de nos volumes calculés par AssemblyNet. Pour cela, nous avons eu recours à plusieurs outils comme notamment la réduction de dimension, la visualisation par boxplots, la réalisation de tests statistiques et enfin, une classification par SVM. Pour mener à bien ces analyses, nous avons donc développé un script sur python.

1) Réduction de dimension

Nous rappelons que les données sur lesquelles nous travaillons comportent initialement 87 dimensions (volumes de chaque région issue d'AssemblyNet). Ainsi, il peut être difficile de les visualiser sur un seul plan. Pour pallier ce problème, nous avons réduit la dimensionnalité de nos données en utilisant trois méthodes : l'Analyse en Composantes Principales (ACP ou PCA anglais), t-distributed stochastic neighbor embedding (t-SNE), Uniform Manifold Approximation and Projection (UMAP). L'objectif a été d'explorer ces trois méthodes et d'évaluer ce que chacune permet de révéler sur la répartition des sujets à travers des nuages de points. L'ACP a pu être réutilisé par la suite pour la classification par SVM, puisque contrairement aux autres méthodes, c'est la seule qui conserve au mieux l'information de la base de données initiales en les projetant de manière linéaire.

Explicitons alors les méthodes de réduction de dimensionnalité utilisées :

a) ACP : C'est une méthode linéaire que nous privilégions pour ce projet. L'ACP consiste à projeter les données sur les axes orthogonaux de variance maximale. Les deux premières composantes principales fournissent alors une projection qui préserve la structure globale du nuage. La méthode permet donc de réduire les données en ne conservant que les composantes principales, tout en préservant au mieux leurs variances, donc leurs structures informatives. Les variables réduites sont donc pertinentes, nous les utiliserons pour la visualisation des sujets colorés par classe et pour la projection des frontières de décision SVM.

b) t-SNE : Concernant cette méthode non linéaire, elle a pour but de préserver les structures locales (voisinages) au détriment de la structure globale, c'est ce qui la rend plus sensible au bruit et à l'initialisation. Par conséquent, c'est une méthode instable, car d'une exécution à l'autre, le voisinage est différent, ce qui amène à une projection dont le résultat varie.

c) UMAP : Enfin, cette méthode préserve simultanément la structure locale et la structure partielle globale, avec un coût computationnel inférieur à celui du t-SNE. C'est ce qui permet d'avoir plusieurs valeurs qui sont testées en parallèle (juxtaposition de plots) pour évaluer la stabilité des structures [5][6].

L'objectif comparatif est d'identifier d'éventuels micro-clusters chez les patients (hétérogénéité phénotypique) par rapport à une distribution plus homogène chez les contrôles.

2) Visualisation de distribution

Dans le but de visualiser la répartition de nos données de manière quantitative, nous avons eu recours aux boxplots (ou boîtes à moustache) qui permettent de représenter les caractéristiques d'un ensemble de données. Ainsi, la boîte délimite l'intervalle interquartile où la première extrémité caractérise le 1er quartile tandis que la deuxième extrémité représente le 3e quartile. Le segment central, quant à lui, met en évidence la médiane [7].

Dans notre cas, nous avons mis en avant la répartition des volumes en fonction des sujets contrôles et patients. Par ailleurs, afin de simplifier, nous avons sélectionné deux régions liées à l'AMS et deux autres régions de références provenant d'AssemblyNet :

— Régions liées à l'AMS : Putamen, Cervelet

— Régions de référence "saines" : Thalamus, Hippocampus

Une ligne rouge horizontale est également tracée et caractérise le volume fourni par l'Atlas Hammers pour la région d'intérêt.

Nous observerons alors en partie **III.A.1**), la manière dont le volume évolue et caractérise l'atrophie ou non liée à la maladie d'AMS.

3) Tests statistiques

Nous avons poursuivi les analyses par des tests statistiques qui nous ont permis de déterminer l'existence ou non de différences significatives entre nos deux classes en nous focalisant seulement sur une ROI à la fois.

Un premier test est celui de Shapiro-Wilk [8] qui a permis de vérifier que la répartition des volumes des groupes (sains et patient) suivait une répartition normale. Cette étape était absolument nécessaire puisque certains tests statistiques requéraient une hypothèse de normalité pour être réalisables.

Dans ce cas, on récupère deux nouveaux groupes sur lesquels on pourra poursuivre les analyses : un groupe de variables suivant une loi normale et un groupe de variables non normales.

Pour l'ensemble des tests statistiques réalisés, le seuil de significativité a été fixé à $p < 0.05$. Ainsi, toute p-valeur inférieure à ce seuil conduit au rejet de l'hypothèse nulle et indique une différence statistiquement significative entre les deux groupes. Dans le cas contraire ($p > 0.05$), l'hypothèse nulle est conservée et la différence observée n'est pas considérée comme significative.

Sur les volumes présentant une distribution normale, on peut appliquer le test de t-test de Student [8]. Ce test nous permet de faire contrôler l'hypothèse nulle selon laquelle les moyennes des

volumes sont égales entre les deux groupes (patients et contrôles). Ce test doit par définition être appliqué à des données ayant une distribution normale.

Sur les données qui suivent des distributions non normales, nous avons effectué deux tests non-paramétriques. Le premier est un test de Mann-Whitney [8], qui nous a permis de vérifier l'hypothèse nulle : il n'y a pas de différence en termes de tendance centrale entre les deux groupes (sains ou contrôles). Les distributions des rangs entre les deux groupes ne présentent pas de différence significative.

Un second test, celui de Kolmogorov-Smirnov, a pu nous apporter des informations sur l'hypothèse nulle : les distributions des deux échantillons présentent une forme globale similaire et donc suivent une loi statistique semblable.

Avec ces informations, particulièrement les tests t-Student et Mann-Whitney, on pourra retrouver les régions révélatrices d'une atrophie. De plus, ces tests servent de compléments à la visualisation par boxplots en soulignant les différences significatives (ou non) entre les deux classes au sein d'un ROI. Cela permet alors de mettre en valeur les ROIs les plus affectées potentiellement par une perte ou une atrophie chez les patients.

C. Entraînement SVM et évaluation

Nous abordons à présent la classification par SVM. Un pré-traitement des données est nécessaire préalablement à l'entraînement de l'algorithme. Ainsi, les caractéristiques d'entrée étant des volumes de ROI exprimés dans des gammes potentiellement hétérogènes, et le SVM reposant sur des distances dans l'espace des caractéristiques, une **standardisation** est appliquée via `StandardScaler`. Afin de prévenir toute fuite d'information, le centrage-réduction est ajusté exclusivement sur l'ensemble d'entraînement (`fit_transform`), puis appliqué à l'ensemble de test (`transform`).

Une fois les données pré-traitées, on établit une séparation des données en deux groupes : 70% de données d'entraînement et 30% pour tester l'algorithme. C'est la méthode standard, mais elle n'est pas établie par le corpus scientifique pour rien, elle favorise une évaluation robuste sur un set de test conséquent.

Une fois cette partie terminée, on réalise une séparation des classes (stratification) afin de préserver la proportion 50/50 des classes dans chaque sous-ensemble. On établit ensuite un entraînement via plusieurs kernels (noyaux) différents afin d'avoir une comparaison exploitable.

Comparaison des noyaux :

— **Linéaire** : $K(x, x') = x^\top x'$

Le noyau linéaire sépare les classes par un hyperplan unique. Il est adapté lorsque les classes sont linéairement séparables et présente l'avantage d'être interprétable, les coefficients du modèle reflétant directement l'importance de chaque ROI dans la décision de classification.

— **Polynomial** : $K(x, x') = (\gamma x^\top x' + r)^d$

Le noyau polynomial introduit une frontière de décision

courbée en projetant les données dans un espace de dimension supérieure via un polynôme d'ordre d . Il capture ainsi des interactions non-linéaires entre les variables, tout en restant plus contrôlé que le noyau RBF. Plus d est élevé, plus la frontière est complexe.

— **RBF (Radial Basis Function)** :

$$K(x, x') = \exp(-\gamma \|x - x'\|^2)$$

Le noyau RBF mesure la similarité entre deux points selon une fonction gaussienne : plus deux points sont proches, plus leur similarité est élevée. Il produit des frontières de décision souples et non-linéaires, capables de s'adapter à des distributions complexes. Cependant, sa flexibilité le rend plus sensible au sur-apprentissage, particulièrement sur des échantillons de petite taille comme le nôtre ($n = 100$).

Afin de comparer les performances des différents kernels, nous établissons des **métriques d'évaluation** notamment avec :

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

La comparaison entre l'accuracy d'entraînement et de test permet de diagnostiquer le régime d'apprentissage du modèle, on a alors :

- $\text{train} \approx \text{test}$ élevé $\rightarrow$ bonne généralisation
- $\text{train} \gg \text{test}$ $\rightarrow$ sur-apprentissage
- train et test faibles $\rightarrow$ sous-apprentissage, il n'a pas suffisamment appris la structure des données

Matrice de confusion : elle permet de visualiser les performances du classifieur en décomposant les prédictions en quatre catégories : les vrais positifs (TP), vrais négatifs (TN), faux positifs (FP) et faux négatifs (FN). Cette matrice offre alors une vue détaillée des erreurs de classification par classe.

$$\text{Précision} = \frac{TP}{(TP + FP)}$$

$$\text{Rappel} = \frac{TP}{(TP + FN)}$$

$$\text{F1-score} = 2 \cdot \frac{\text{Précision} \cdot \text{Rappel}}{(\text{Précision} + \text{Rappel})}$$

Validation croisée : la validation croisée en k blocs (k -fold) partitionne l'ensemble d'entraînement en k sous-ensembles dis-joints. Le modèle est entraîné sur $k - 1$ blocs et évalué sur le bloc restant, l'opération étant répétée k fois et la performance finale correspond à la moyenne des k scores, ce qui réduit la variance de l'estimation et limite la dépendance au partitionnement initial.

Dans le but de visualiser la frontière de décision du SVM, nous avons eu recours à une projection de nos données dans un espace 2D réalisée à l'aide d'une ACP. Nous avons alors ré-entraîné le modèle sur les deux composantes principales. De cette façon, nous obtenons une meilleure visualisation concernant la séparabilité des classes selon le noyau utilisé.

III. RÉSULTATS

A. Analyse exploratoire et statistique

1) ACP

Nous avons traité de la réduction de dimension plus tôt pour évoquer la visualisation de nos données dans un espace 2D. La figure 1 met en avant la répartition de nos données à travers une ACP. On peut alors observer un rassemblement des données en fonction du groupe auquel ils appartiennent (patients ou contrôles). Par ailleurs, il faut souligner l'hétérogénéité observée chez les patients : un chevauchement important persiste entre les points des différentes classes, traduisant une variabilité intra-classe et une difficulté potentielle à séparer les deux groupes lorsque toutes les régions sont incluses. Pour adhérer à ce chevauchement, nous avons réalisé des essais complémentaires reposant sur d'autres méthodes de réduction et de visualisation des données, notamment t-SNE et UMAP (*nous analyserons en détail ces résultats ultérieurement dans la partie "discussion"*)




FIGURE 1 – ACP

Les réductions de dimension réalisées par t-SNE et UMAP ne seront pas traitées. Cependant, les résultats sont visibles en Annexe B.

2) Boxplots

Précédemment, nous avons évoqué le Putamen, le Cervelet, le Thalamus ainsi que l'Hippocampus comme régions que nous allons étudier pour observer l'évolution des volumes. Ainsi, les figures figure 2 et figure 3 mettent en avant les boxplots liés au Putamen et au Thalamus que nous allons étudier dès à présent. Les boxplots relatifs au Cervelet et à l'Hippocampus sont présents en Annexe A.

Commençons avec le boxplot Putamen. Sur la figure 2, on peut noter que les sujets contrôles possèdent un putamen dont la densité est plus importante que celle des sujets patients. En effet, on observe que 50% des contrôles possèdent un volume entre 0.57% et 0.66% avec une valeur minimale à 0.52% et maximale à 0.79%. Cependant, les volumes de patients montrent un volume bien plus faible avec 50% des volumes répartis entre 0.36% et 0.56% ainsi que des valeurs minimales à 0.24%. De cette manière, on peut souligner que les deux clusters ne montrent pas une séparation

marquante. En effet, près de la moitié des patients présentent des volumes du Putamen similaires à ceux des sujets sains, on note alors un chevauchement entre les classes.

D'autre part, on remarquera que le volume fixé par l'Atlas (ligne verte) est compris dans ceux récupérés par AssemblyNet. On regarde ici seulement les sujets de contrôle, car l'Atlas regroupe seulement des volumes cérébraux sains.




FIGURE 2 – Boxplot Putamen

En ce qui concerne le Thalamus, on remarque une homogénéité bien plus visible au niveau de la répartition des volumes avec notamment un volume bien plus dense de la région. En effet, on peut tout d'abord observer dans le groupe de contrôle, un volume minimal moyen de 0.83%. De plus, 50% de ce même groupe possèdent un volume entre 1.02% et 1.14% pendant que 50% des patients détiennent un Thalamus entre 0.96% et 1.08%. Les médianes sont alors à 1.07% et 1.04%. Par ailleurs, l'Atlas Hammers fixe le volume à 1.18%,

On peut noter une différence entre le volume issu de l'Atlas et celui-là distribution des sujets contrôles de 0.04%. Bien que légèrement supérieur à la médiane et proche du 3e quartile dans le cas du thalamus, il demeure compatible et reste cohérent avec la variabilité observée dans cette population.




FIGURE 3 – Boxplot Thalamus

À partir des résultats ci-dessus, on montre effectivement que la maladie d'AMS touche certaines régions plus que d'autres. Ainsi, le Putamen est plus sujet à une atrophie que le Thalamus et cela se remarque davantage lors de la comparaison des sujets contrôles aux sujets patients.

3) Tests Statistiques

Les résultats des tests que nous avons réalisés sur les volumes des régions fournis par AssemblyNet sont les suivants. Le test de Shapiro-Wilk a révélé 64 régions où les deux groupes suivent une distribution normale et 23 régions avec au moins un groupe présentant une distribution non normale.

Sur les 64 régions, le test t-Student a révélé 29 régions présentant une différence significative entre les moyennes des deux groupes au seuil de 95%.

Sur les 23 régions, seules 6 régions présentent une différence significative entre les distributions des rangs des volumes avec le test de Mann-Whitney. Le test de Kolmogorov-Smirnov lui identifie, 9 régions présentant une différence de distribution significative et 14 non significative.

Au total, quand on s'intéresse aux dispersions des volumes, on remarque que sur les 87 régions initiales, 39 régions ont révélé des différences de distribution significatives, soit environ 45% des régions analysées du cerveau. Certaines régions comme le Putamen (t-test), Cervelet (t-test) ou le tronc cérébral (t-test), sont particulièrement touchées par l'AMS, comme reconnu dans l'article [9]. Ce sont des régions généralement atteintes dans le cas d'une MSA-C et d'une MSA-P. En revanche, on en trouve aussi d'autres comme le segment médial du Gyrus Frontal Supérieur (Mann-Whitney) et le Cortex entorhinal (t-test).

B. Performance SVM et frontières de décision

À l'aide de la figure 4 on peut observer les frontières de décision des trois noyaux SVM (linéaire, polynomial, RBF) projetées dans l'espace ACP 2D.




FIGURE 4 – Visualisation 2D de la frontière de décision du SVM entraîné sur les deux composantes de la PCA selon différents types de noyaux

Comme explicité précédemment, le noyau **linéaire** produit une séparation par hyperplan unique dans l'espace projeté : la frontière est rectiligne. Cependant, on constate plusieurs erreurs de classification aux abords de la frontière, où les nuages des deux classes se chevauchent. Concernant le noyau **polynomial**, il introduit une légère courbure, mais la topologie de séparation reste proche du cas linéaire, ce qui suggère que les interactions polynomiales d'ordre supérieur n'apportent pas de gain structurel notable sur cette projection 2D. Pour finir, le noyau **RBF** produit une frontière fermée englobant la zone dense des contrôles avec quelques erreurs. Visuellement, cette segmentation paraît mieux adaptée à la distribution observée. Le tableau ci-dessous met en avant les métriques associées à ces trois noyaux, mais nous allons nous concentrer davantage sur le noyau RBF.

	Kernel		
	Linear	Polynomial	RBF
Train acc.	100%	92.9 %	97.1%
Test acc.	73.3%	73.3%	90%
CV 5-fold	84.3% $\pm$ 8.3%	75.7% $\pm$ 7.3%	75.7% $\pm$ 9.7%

TABLE 1 – Comparaison des performances des kernels SVM

En ce qui concerne le kernel linéaire, l'accuracy d'entraînement atteint (100.0%), contre seulement (73.3%) pour l'accuracy de test. Cet écart traduit un sur-apprentissage, attribuable à la petite taille de l'échantillon. Toutefois, la validation croisée à $(84.3 \pm 8.3\%)$ constitue le meilleur score de généralisation des trois noyaux.

Pour le kernel polynomial, l'accuracy d'entraînement (92.9%) et de test (73.3%) présente un écart marqué, et la validation croisée à $75.7 \pm 7.3\%$ confirme une généralisation médiocre, équivalente à celle du RBF mais inférieure au linéaire. La complexité introduite par le polynôme d'ordre supérieur n'apporte aucun gain : le modèle tend à mémoriser les données d'entraînement plutôt qu'à apprendre une structure généralisable.

Enfin, l'écart entre l'accuracy d'entraînement (97.1%) et de test (90.0%) reste modéré pour le kernel RBF, mais la validation croisée 5-fold à $75.7\% \pm 9.7\%$ révèle une instabilité significative de la performance selon le découpage des données. L'écart entre l'accuracy test du holdout (90%) et la moyenne CV (75.7%) suggère que le score de test reflète une partition favorable plutôt qu'une généralisation robuste. L'écart-type élevé ($\pm 9.7\%$) traduit la sensibilité du modèle à la composition des plis, conséquence directe

de la taille d'échantillon réduite ($n = 100$) et de la complexité du noyau RBF qui favorise le sur-apprentissage local.

D'autant plus que, la symétrie entre précision et rappel des deux classes ($F1 = 0.90$ pour chacune) toujours pour le kernel RBF (Annexe D) indique l'absence de biais de classe, cohérente avec la séparation de classe appliquée.

Au final, le modèle le plus prometteur en termes de compromis entre les performances de précision et la capacité de généralisation du modèle est celui avec le noyau RBF, malgré sa variabilité de validation croisée, d'autant plus que la frontière entre les deux classes est non linéaire

IV. DISCUSSION

Outre l'ACP, deux autres méthodes de réduction de dimension ont été mises en œuvre : la t-SNE et l'UMAP (Annexe B). Nous pouvons alors observer que la t-SNE préserve les distances locales et tend à former des clusters distincts avec une bonne séparation entre les deux groupes, mais produit un étalement croissant des données à mesure que le nombre de voisins augmente. D'autre part, l'UMAP, qui conserve à la fois la structure locale et globale, offre une dispersion plus stable et des représentations plus compactes, tout en maintenant une séparation satisfaisante entre les groupes.

Tout au long de ce projet, nous nous sommes concentrés sur quatre régions en particulier : le Putamen, le Cervelet, l'Hippocampe ainsi que le Thalamus. Par ailleurs, en ce qui concerne les boxplots, notre attention s'est portée le Putamen ainsi que sur le Thalamus. Cependant, les résultats portant sur le Cerebellum et l'Hippocampus sont tout aussi intéressants. En effet, si l'on se réfère à la figure Aa et la figure Ab de l'Annexe A, ce que nous avons obtenu est relativement similaire aux résultats vu précédemment.

Pour le Cervelet, on retrouve des volumes de sujets contrôles plus importants que ceux des sujets malades. On notera une médiane à 9% pour les sujets contrôles alors qu'elle est de 8% pour les sujets malades. On observe alors une atrophie du volume qui se caractérise par une différence de 1% entre les deux groupes.

En ce qui concerne l'Hippocampus, la différence des médianes des deux groupes est insignifiante. Par ailleurs, nous pouvons noter que les volumes des sujets patients restent compris dans l'intervalle de volumes des sujets contrôles. Toutefois, nous remarquons une légère diminution des volumes bien qu'elle soit faible.

Finalement, le volume du Cervelet ainsi que de l'Hippocampus extraits par l'Atlas Hammers sont, quant à eux, bien différents des volumes récupérés par AssemblyNet. En effet, on remarque une différence de 2% pour le Cervelet (médiane à 9% pour AssemblyNet contre 11.1% pour l'Atlas) ainsi qu'une différence de 0.18% pour l'Hippocampus (médiane à 0.52% pour AssemblyNet). Ces résultats montrent une divergence vis-à-vis des volumes segmentés par AssemblyNet et par l'Atlas Hammers.

Lors de l'analyse exploratoire à l'aide de tests statistiques, il a été révélé que 39 des 87 régions étudiées (soit environ 45% des

structures) présentent une différence statistiquement significative entre les sujets sains et les patients atteints d'AMS. De plus, les régions les plus discriminantes, telles que le Putamen, le cervelet et le tronc cérébral, concordent avec la littérature neuropathologique sur ces résultats. En parallèle, on observe que le thalamus, considéré comme une région relativement épargnée par l'AMS, ne présente que peu de perturbations, avec une superposition quasi identique entre les deux groupes, aussi bien chez les patients que chez les sujets contrôles. Lors de la projection ACP 2D, cela nous révèle une structure de séparation à dominante linéaire, mais avec un chevauchement marqué aux frontières interclasses, traduisant l'hétérogénéité intra-groupe de sujets patients.

Les trois noyaux testés se comportent de la manière suivante :

- **Linéaire** : produit une frontière stricte, insensible à l'hétérogénéité locale des classes. Sa rigidité limite la capacité à capter les zones de chevauchement.
- **Polynomial** : offre une flexibilité intermédiaire. Le paramètre de degré d n'a pas été exploré systématiquement ; une valeur plus élevée pourrait mieux capter la variabilité non linéaire des données et améliorer la séparation aux frontières.
- **RBF** : retenu comme le plus performant (90 % en holdout 70/30 ; $75.7\% \pm 9.7\%$ en validation croisée 5 plis). L'écart entre les deux estimations traduit un léger sur-apprentissage et une dépendance au tirage du holdout.

Concernant la classification SVM, le choix du noyau RBF demande à être nuancé : l'accuracy de 90% obtenue sur la partition 70/30 surestime la capacité réelle de généralisation, comme le montre la chute à 75.7% ($\pm 9.7\%$) en validation croisée 5-fold. Au-delà, l'hétérogénéité clinique évoquée précédemment, on observe une seconde limite qui traduit l'absence d'optimisation des hyperparamètres : C (compromis entre largeur de marge et tolérance aux erreurs de classification) et γ (portée d'influence d'un vecteur support pour le noyau RBF) ont été conservés à leurs valeurs par défaut, de même que le degré d et le coefficient coeff0 pour le noyau polynomial. Or, un γ trop élevé restreint l'influence des vecteurs supports à un voisinage local, produisant des frontières de décision trop ajustées aux données d'entraînement, ce qui est cohérent avec l'écart observé entre l'accuracy d'entraînement (97.1%) et celle de test (90.0%). Une recherche systématique des hyperparamètres, idéalement couplée à une validation croisée stratifiée tenant compte du stade clinique des patients, constituerait une amélioration directe de la robustesse du classifieur.

Ensuite, vis-à-vis de la segmentation, la différence notable des 87 ROI d'AssemblyNet contre les 68 ROI de Hammers, pour un total de 18 régions communes après corrélation des atlas, est représentative des limites apportées par les atlas en question. De ce fait, on ne peut avoir une définition de morphologie cérébrale limpide entre les sujets que ce soit pour les contrôles, mais d'autant plus avec les patients puisque l'atrophie imposée par l'AMS ajoute de

la déformation tissulaire qui n'est pas prise en considération dans les bases d'atlas **Hammers**. Pour **AssemblyNet** c'est différent, son apprentissage direct sur des données annotées permettant l'attribution d'étiquettes à chaque voxel via les CNN 3D a permis de contourner cette limite. On a donc pu se servir des Atlas dans les boxplot, **Hammers** nous servant des références (ligne verte dans les boxplots) et **AssemblyNet** pour les divergences autour de cette référence nous offrant une approche volumétrique par individu.

Pour le choix du noyau, cela s'est fait d'un constat des performances de chacun, bien qu'ils convergent tous au niveau des frontières visuelles de l'espace ACP 2D, et que la structure de séparation entre les deux classes soit dominée par une composante linéaire, le choix des noyaux entre RBF et polynomial était de mise puisqu'il apporte tous deux un gain aux abords des frontières là où les classes se chevauchent. Pour finir, le choix du RBF a été considéré pour "meilleur" au vu des résultats émis, cependant ce choix reste à nuancer puisque comme expliqué précédemment la validation croisée (75.7%) traduit une dépendance liée au holdout et peut être due à un sur-apprentissage.

Dans cette même continuité, on peut aborder les limites liées à notre modèle, commençons avec le fais qu'il s'agit de 100 sujets générés à partir de profils cliniques. De ce fait cela impose des restrictions notamment entre la corrélation inter-régionale de chaque individu et le fait de ne pas pouvoir transposer ce modèle dans un contexte clinique. De plus, le fais de n'avoir que 100 échantillons a démontré que la variance des estimateurs de performance ($CV \pm 9.7\%$) était relativement élevée, ce qui est problématique car cela signifie une perte de précision de la classification. Ainsi, une augmentation d'échantillon aurait été plus adaptée à ce modèle. On ne peut également pas négliger l'optimisation des hyperparamètres, qui aurait pu mieux orienter le choix du noyau ou améliorer les résultats, notamment en levant la limitation actuelle des comparaisons inter-noyaux au profit du seul RBF.

Concernant les perspectives ouvertes par ce travail exploratoire, plusieurs pistes peuvent être envisagées. Une validation sur données réelles d'IRM de patients atteints d'AMS permettrait de vérifier la reproductibilité des résultats observés, tant pour les régions discriminantes que pour la séparabilité par SVM. Une augmentation de l'effectif réduirait la variance des estimateurs et stabiliserait les performances du modèle. Enfin, l'exploration de modèles alternatifs tels que les *Random Forest* ou d'autres approches non linéaires, ainsi que la comparaison avec les travaux publiés dans la littérature, constituerait des extensions pertinentes.

Pour conclure, bien que ce travail demeure exploratoire, d'un point de vue méthodologique, il serait préférable d'évaluer et d'utiliser les performances du modèle à l'aide d'une validation croisée stratifiée de 5 à 10 folds, en utilisant la moyenne des scores obtenus, ainsi que leur écart-type, plutôt que de se limiter à l'accuracy issue d'un unique découpage des données. De cette manière, on réduit le risque de surestimation des performances

et on peut obtenir une estimation plus robuste et plus fiable de la capacité de généralisation du modèle.

V. CONCLUSION

Ce projet avait pour objectif d'explorer la segmentation automatique par **AssemblyNet** dans le cadre de la classification de la maladie d'AMS à partir de volumes cérébraux issus d'IRM pondérées en T1.

L'analyse exploratoire a confirmé la pertinence des données volumétriques pour distinguer les sujets sains des patients AMS. En effet, environ 45% des 87 régions cérébrales analysées présentent des différences statistiquement significatives entre les deux groupes avec notamment une atteinte marquée du Putamen et du Cervelet, structures classiquement impliquées dans l'AMS, tandis que des régions a priori épargnées comme le Thalamus montrent une distribution quasi identique entre les deux groupes, ce qui valide la cohérence anatomique et quantitative de notre approche.


Sur le plan de la classification, le SVM à noyau RBF a obtenu les meilleures performances apparentes avec une accuracy de test de 90% sur le découpage 70/30. Cependant, la validation croisée à 5 folds ramène cette estimation à 75.7% ($\pm 9.7\%$), révélant une instabilité liée à la petite taille de l'échantillon ($n = 100$) et au risque de sur-apprentissage propre au noyau RBF. Ces résultats soulignent alors la nécessité d'une évaluation rigoureuse par validation croisée pour éviter toute surestimation des capacités de généralisation du modèle.

RÉFÉRENCES


- [1] *Atrophie multisystématisée (AMS)*, fr, juin 2025. visité le 15 mars 2026. adresse : <https://www.chu-toulouse.fr/atrophie-multisystematisee-ams>.
- [2] *Atrophie multisystémique (AMS) - Troubles du cerveau, de la moelle épinière et des nerfs*, fr. visité le 15 mars 2026. adresse : <https://www.msmanuals.com/fr/accueil/troubles-du-cerveau-de-la-moelle-%C3%A9pini%C3%A8re-et-des-nerfs/troubles-du-syst%C3%A8me-nerveux-autonome/atrophie-multisyst%C3%A9mique-ams>.
- [3] A. HAMMERS et al., "Three-dimensional maximum probability atlas of the human brain, with particular reference to the temporal lobe," en, *Human Brain Mapping*, t. 19, n° 4, p. 224-247, août 2003, ISSN : 1097-0193. DOI : 10.1002/hbm.10123. visité le 7 mai 2026. adresse : <https://onlinelibrary.wiley.com/doi/10.1002/hbm.10123>.
- [4] P. COUPÉ et al., "AssemblyNet : A large ensemble of CNNs for 3D whole brain MRI segmentation," *NeuroImage*, t. 219, p. 117026, oct. 2020, ISSN : 1053-8119. DOI : 10.1016/j.neuroimage.2020.117026. visité le 15 mars 2026. adresse : <https://www.sciencedirect.com/science/article/pii/S1053811920305127>.
- [5] *UMAP : Uniform Manifold Approximation and Projection for Dimension Reduction — umap 0.5.8 document*

- tation. visité le 7 avr. 2026. adresse : <https://umap-learn.readthedocs.io/en/latest/>.
- [6] STATQUEST WITH JOSH STARMER, *UMAP Dimension Reduction, Main Ideas!!!* Mars 2022. visité le 8 avr. 2026. adresse : <https://www.youtube.com/watch?v=eN0wFzBA4Sc>.
- [7] *Diagramme à moustaches (Boxplot) - Excel – Fonctions, exemples et problématiques connues - Confluence*. visité le 25 avr. 2026. adresse : <https://hecmontreal.atlassian.net/wiki/spaces/FEXC/pages/2985164814/Diagramme+moustaches+Boxplot>.
- [8] *t-Test, khi-deux, ANOVA, Régression, Corrélation...* fr. visité le 25 avr. 2026. adresse : <https://numiqo.fr/tutorial/test-of-normality>.
- [9] H.-J. HUPPERTZ et al., "Differentiation of neurodegenerative parkinsonian syndromes by volumetric magnetic resonance imaging analysis and support vector machine classification," en, *Movement Disorders*, t. 31, n° 10, p. 1506-1517, oct. 2016, ISSN : 0885-3185, 1531-8257. DOI : 10.1002/mds.26715. visité le 26 mars 2026. adresse : <https://movementdisorders.onlinelibrary.wiley.com/doi/10.1002/mds.26715>.
- [10] V. VAPNIK, S. GOLOWICH et A. SMOLA, "Support Vector Method for Function Approximation, Regression Estimation and Signal Processing," in *Advances in Neural Information Processing Systems*, t. 9, MIT Press, 1996. visité le 15 mars 2026. adresse : https://proceedings.neurips.cc/paper_files/paper/1996/hash/4f284803bd0966cc24fa8683a34afc6e-Abstract.html.
- [11] L. CHOUGAR et al., "Automated Categorization of Parkinsonian Syndromes Using Magnetic Resonance Imaging in a Clinical Setting," en, *Movement Disorders*, t. 36, n° 2, p. 460-470, fév. 2021, ISSN : 0885-3185, 1531-8257. DOI : 10.1002/mds.28348. visité le 26 mars 2026. adresse : <https://movementdisorders.onlinelibrary.wiley.com/doi/10.1002/mds.28348>.

ANNEXES




(a) Boxplot Cervelet




(b) Boxplot Hippocampus


ANNEXE A – Boxplots du Cervelet et de l'Hippocampus




(a) t-SNE avec 5 n-neighbors



(b) Umap avec 5 n-neighbors



(c) t-SNE avec 20 n-neighbors



(d) Umap avec 20 n-neighbors

ANNEXE B – Réduction de dimension avec différents paramètres

```

Kernel: poly
Acc train: 0.929
Acc test: 0.733
CV 5-fold: 0.757 ± 0.073

```

	precision	recall	f1-score	support
0	0.68	0.87	0.76	15
1	0.82	0.60	0.69	15
accuracy			0.73	30
macro avg	0.75	0.73	0.73	30
weighted avg	0.75	0.73	0.73	30

(a) SVM avec kernel polynomial

```

Kernel: linear
Acc train: 1.000
Acc test: 0.733
CV 5-fold: 0.843 ± 0.083

```

	precision	recall	f1-score	support
0	0.71	0.80	0.75	15
1	0.77	0.67	0.71	15
accuracy			0.73	30
macro avg	0.74	0.73	0.73	30
weighted avg	0.74	0.73	0.73	30

(b) SVM avec kernel linéaire

ANNEXE C

```

Kernel: rbf
Acc train: 0.971
Acc test: 0.900
CV 5-fold: 0.757 ± 0.097

```

	precision	recall	f1-score	support
0	0.93	0.87	0.90	15
1	0.88	0.93	0.90	15
accuracy			0.90	30
macro avg	0.90	0.90	0.90	30
weighted avg	0.90	0.90	0.90	30

ANNEXE D – SVM avec kernel RBF

Variance expliquée PCA (70/30): [0.40746138 0.11357531]

ANNEXE E – Variance PCA