




Exploration de la segmentation automatique par AssemblyNet pour la classification d'une maladie neurodégénérative

KISX8AFU - Initiation à la Recherche et Projet

Mai 2026 - M1 Imagerie Médicale

Présenté par :

ASSIDAH Asma
22203679

MASSON Louis
22508017

ZIRN Léna
22504902

Sommaire

I. Introduction

II. Matériel et méthodes

II.1. Méthodes d'analyse

II.2. Méthodes statistiques

II.3. Machine à vecteurs de support (SVM)

III. Résultats

III.1. Analyse exploratoire

III.2. Analyse statistique

III.3. Classification par SVM

IV. Discussion

V. Conclusion

I. Introduction

IRM Pondération T1




Figure 1 : Image IRM cerveau sain pondérée en T1 [1]

AMS : Atrophie Multi-Systématisée





Figure 2 : Régions du cerveau atteintes par l'AMS [2]

Données



I. Introduction

Approches de segmentation

Segmentation classique




Figure 3 : Atlas Hammer

Figure 4 : Atlas Hammer
projeté sur un patient

Segmentation Automatique




Figure 5 : Schéma de fonctionnement de Assembly [3]

Utilisation des volumes des régions segmentées dans les SVM

II.1. Méthodes d'exploration : ACP et boxplots

Analyse en Composantes Principales




Figure 6 : ACP [4]

- 87 régions → visualisation difficile
- Projection des données sur des axes de variance maximale
- Sujets patients : hétérogénéité des volumes
- Sujets contrôles : homogénéité des volumes

II.1. Méthodes d'exploration : ACP et boxplots

Analyse en Composantes Principales




Figure 6 : ACP [4]

- 87 régions → visualisation difficile
- Projection des données sur des axes de variance maximale
- Sujets patients : hétérogénéité des volumes
- Sujets contrôles : homogénéité des volumes

Boxplot




Figure 7 : Exemple d'une Boxplot [5]

Comparaison volumes cérébraux AssemblyNet :

Régions AMS

-Putamen

-Cervelet

Régions saines

-Thalamus

-Hippocampe

II.2. Méthodes d'analyse : tests statistiques

Données : patients et contrôles

$p < 0.05$



II.2. Méthodes d'analyse : tests statistiques

Données : patients et contrôles



Test de Shapiro-Wilk
(normalité)

$p < 0.05$



II.2. Méthodes d'analyse : tests statistiques

Données : patients et contrôles

↓
Test de Shapiro-Wilk
(normalité)

$p < 0.05$

↓
Distribution normale

↓
Distribution non-normale

II.2. Méthodes d'analyse : tests statistiques

Données : patients et contrôles

↓
Test de Shapiro-Wilk
(normalité)

$p < 0.05$

↓
Distribution normale

↓
Distribution non-normale

↓
T-test de Student
(moyennes)

II.2. Méthodes d'analyse : tests statistiques

Données : patients et contrôles

↓
Test de Shapiro-Wilk
(normalité)

$p < 0.05$

↓
Distribution normale

↓
T-test de Student
(moyennes)

↓
Distribution non-normale

↓
Test de Mann-Whitney
(tendances centrales)

II.2. Méthodes d'analyse : tests statistiques

Données : patients et contrôles

Test de Shapiro-Wilk
(normalité)

$p < 0.05$

Distribution normale

Distribution non-normale

T-test de Student
(moyennes)

Test de Kolmogorov-Smirnov
(similarité globale des
distributions)

Test de Mann-Whitney
(tendances centrales)

II.3. Machine à vecteurs de support (SVM)

Prétraîtement

- Problème : volumes ROI à échelles hétérogènes → SVM sensibles aux distances dans l'espace des caractéristiques
- Solution : standardisation (centrage-réduction)
- Anti-fuite : ajustement (fit) sur train uniquement → application (transform) sur test

Partition des données

- Train 70 % / Test 30 %.
- Stratification : conservation du ratio 50/50 des classes dans chaque sous-ensemble



II.3. Machine à vecteurs de support (SVM)

Comparaison des noyaux

- Linéaire
 - Frontière : hyperplan unique
 - Avantage : interprétabilité
 - Limite : séparation linéaire requise
- Polynomial
 - Frontière : courbe paramétrée par le degré d
 - Capte les interactions non linéaires entre variables
- RBF (gaussien)
 - Frontière : souple, locale, adaptée aux distributions complexes
 - Risque : sur-apprentissage accru sur petits échantillons




Figure 8 :
kernel linéaire [6]




Figure 9 :
kernel polynomial [6]




Figure 10 :
kernel RBF [6]

II.3. Machine à vecteurs de support (SVM)

Métrique d'évaluation

- Accuracy train et test
 - Diagnostic du régime d'apprentissage
 - Écart important → sur-apprentissage




Figure 11 : Exemple accuracy train et test

Matrice de confusion + métriques par classe

- VP, FP, VN, FN
- Précision, Rappel, F1-score

		Reality	
		Negative : 0	Positive : 1
Prediction	Negative : 0	True Negative : TN	False Negative : FN
	Positive : 1	False Positive : FP	True Positive : TP

		Accuracy Actual	
		0	1
Prediction	0	TN	FN
	1	FP	TP

		Precision Actual	
		0	1
Prediction	0	TN	FN
	1	FP	TP

		Recall Actual	
		0	1
Prediction	0	TN	FN
	1	FP	TP

Figure 12 : Matrice de confusion et métrique par classe [7]

II.3. Machine à vecteurs de support (SVM)

Métrique d'évaluation

Validation croisée 5 plis

- Train partitionné en 5 blocs :
4 entraînements + 1 test = 5 itérations
- Moyenne → réduction de la variance d'estimation, indépendance au tirage

Visualisation 2D

- Projection ACP sur 2 composantes principales
- Réentraînement du modèle pour tracer les frontières de décision




Figure 13 : Validation croisée de 5 plis [8]




Figure 14 : Représentation de la distribution par ACP

III.1. Analyse exploratoire : ACP




Figure 14 : Représentation de la distribution par ACP

III.1. Analyse exploratoire : boxplots




Figure 15 : Visualisation de la distribution des volumes du Putamen pour les deux groupes




Figure 16 : Visualisation de la distribution des volumes du Thalamus pour les deux groupes

III.2. Analyse statistique

Données : **87** régions

$p < 0.05$

Test de Shapiro-Wilk

Distribution normale

64 régions

Distribution non-normale

23 régions

T-test de Student

29 régions

Test de Kolmogorov-Smirnov

9 régions

Test de Mann-Whitney

6 régions

Total : **39** régions significativement différentes (**~45%**)

III.2. Analyse statistique

$p < 0.05$

Total : **39** régions significativement différentes (~**45%**)

Régions attendues




Figure 17 : Région du cerveau typiquement atteinte par l'AMS [2]

Régions non-attendues



Figure 18 : Gyrus Frontal Supérieur [9]




Figure 19 : Cortex entorhinale [10]

III.3. SVM




Figure 20 : Visualisation 2D de la frontière de décision du SVM entraîné sur les deux composantes de l'ACP selon différents types de noyaux

III.3. SVM




Figure 21 : Visualisation 2D de la frontière de décision du SVM entraîné sur les deux composantes de l’ACP selon différents types de noyaux

	Kernel		
	Linear	Polynomial	RBF
Train acc.	100%	92.9 %	97.1%
Test acc.	73.3%	73.3%	90%
CV 5-fold	84.3% ± 8.3%	75.7% ± 7.3%	75.7% ± 9.7%

Figure 22 : Tableau comparatif des performances des kernels SVM

III.3. SVM

	Kernel		
	Linear	Polynomial	RBF
Train acc.	100%	92.9 %	97.1%
Test acc.	73.3%	73.3%	90%
CV 5-fold	84.3% $\pm$ 8.3%	75.7% $\pm$ 7.3%	75.7% $\pm$ 9.7%

Figure 23 : Tableau comparatif des performances des kernels SVM

Linéaire

- Meilleur score de généralisation
- Sur-apprentissage présent mais simplicité = robustesse sur petit échantillon

Polynomiale

- Complexité ajoutée sans gain $\rightarrow$ mémorisation, pas de structure généralisable

RBF

- Écart-type CV élevé $\rightarrow$ instabilité selon découpage.

III.3. SVM

	Kernel		
	Linear	Polynomial	RBF
Train acc.	100%	92.9 %	97.1%
Test acc.	73.3%	73.3%	90%
CV 5-fold	84.3% $\pm$ 8.3%	75.7% $\pm$ 7.3%	75.7% $\pm$ 9.7%

Figure 23 : Tableau comparatif des performances des kernels SVM

Linéaire

- Meilleur CV (84.3 % $\pm$ 8.3) mais rigidité géométrique $\rightarrow$ incapable de capturer la non-linéarité visible en projection ACP

RBF

- CV inférieure et plus variable (75.7 % $\pm$ 9.7) mais flexibilité épousant la frontière réelle des classes

On privilégie l'adéquation géométrique au CV-fold

IV. Discussion

Boxplots/Tests statistiques

Cervelet
tronc cérébral
Putamen

} → touchées par l'AMS

IV. Discussion

Boxplots/Tests statistiques

Cervelet
tronc cérébral
Putamen

} → touchées par l'AMS

Classification SVM

Noyau RBF : 90% accuracy → Meilleures performances

Validation 5-fold : 75.7% accuracy

Sur-apprentissage et dépendance des données extraites

IV. Discussion

Boxplots/Tests statistiques

Cervelet
tronc cérébral
Putamen

} → touchées par l'AMS

Limites

Hyperparamètres C et γ non optimisés
Nombre d'échantillons utilisés insuffisant (n=100)
Échantillons synthétiques

Classification SVM

Noyau RBF : 90% accuracy → Meilleures performances
Validation 5-fold : 75.7% accuracy
Sur-apprentissage et dépendance des données extraites

IV. Discussion

Boxplots/Tests statistiques

Cervelet
tronc cérébral
Putamen

} → touchées par l'AMS

Limites

Hyperparamètres C et γ non optimisés
Nombre d'échantillons utilisés insuffisant (n=100)
Échantillons synthétiques

Classification SVM

Noyau RBF : 90% accuracy → Meilleures performances
Validation 5-fold : 75.7% accuracy
Sur-apprentissage et dépendance des données extraites

Perspectives

Détermination hyperparamètres optimisés C et γ
Augmentation de l'effectif
Validation sur données IRM réelles
Modèles alternatifs : Random Forest

V. Conclusion

- Objectif : évaluer AssemblyNet pour classification AMS vs sains sur IRM T1
- Analyse exploratoire : 45 % des 87 ROI significativement différentes (putamen, cervelet)
- Classification SVM-RBF : test 90 % et CV $75.7 \% \pm 9.7$ → écart révélateur des limites lié à la taille d'échantillon $n = 100$
- Enseignement méthodologique : holdout < validation croisée < aspect géométrique

Merci de votre
attention

Bibliographie

- [1] « Posterior reversible encephalopathy syndrome (PRES) | Radiology Case | Radiopaedia.org ». Consulté le: 9 mai 2026. [En ligne]. Disponible sur: [‘posterior-reversible-encephalopathy-syndrome-pres-33’](https://radiopaedia.org/cases/posterior-reversible-encephalopathy-syndrome-pres-33) Accessed: May. 08, 2026. [Online]. Available: <https://radiopaedia.org/cases/posterior-reversible-encephalopathy-syndrome-pres-33>
- [2] « Atrophie multisystémique (AMS) - Troubles du cerveau, de la moelle épinière et des nerfs », Manuels MSD pour le grand public. Consulté le: 15 mars 2026. [En ligne]. Disponible sur: https://www.msdmanuals.com/fr/accueil/troubles-du-cerveau-de-la-moelle-%C3%A9pini%C3%A8re-et-des-nerfs/troubles-du-syst%C3%A8me-nerveux-autonome/atrophie-multisyst%C3%A9mique-ams#Causes_v21853750_fr
- [3] P. Coupé et al., « AssemblyNet: A large ensemble of CNNs for 3D whole brain MRI segmentation », NeuroImage, vol. 219, p. 117026, oct. 2020, doi: [10.1016/j.neuroimage.2020.117026](https://doi.org/10.1016/j.neuroimage.2020.117026).
- [4] « Dimensionality Reduction Techniques », GeeksforGeeks. Consulté le: 9 mai 2026. [En ligne]. Disponible sur: <https://www.geeksforgeeks.org/data-science/dimensionality-reduction-techniques/>
- [5] V. A. D, « Python Boxplot - How to create and interpret boxplots (also find outliers and summarize distributions) », machinelearningplus. Consulté le: 9 mai 2026. [En ligne]. Disponible sur: <https://machinelearningplus.com/plots/python-boxplot/>
- [6] Fiche de présentation du projet IRP, OSMAN Noura. Consulté le: 13 mars 2026. [En ligne]. Disponible sur: Moodle
- [7] CM Bureau d’études Apprentissage automatique (machine learning) Shahram.Hosseini
- [8] « Données de rétention et validation croisée | Aide Qlik Cloud ». Consulté le: 9 mai 2026. [En ligne]. Disponible sur: https://help.qlik.com/fr-FR/cloud-services/Subsystems/Hub/Content/Sense_Hub/AutoML/holdout-crossvalidation.htm
- [9] « Gyrus frontal supérieur », Wikipédia. 29 décembre 2024. Consulté le: 9 mai 2026. [En ligne]. Disponible sur: https://fr.wikipedia.org/wiki/Gyrus_frontal_sup%C3%A9rieur
- [10] « Entorhinal cortex », Wikipedia. 31 décembre 2025. Consulté le: 9 mai 2026. [En ligne]. Disponible sur: https://en.wikipedia.org/w/index.php?title=Entorhinal_cortex&oldid=1330494193

Bibliographie

- [12] P. Coupé et al., « AssemblyNet: A large ensemble of CNNs for 3D whole brain MRI segmentation », NeuroImage, vol. 219, p. 117026, oct. 2020, doi: [10.1016/j.neuroimage.2020.117026](https://doi.org/10.1016/j.neuroimage.2020.117026).
- [13] L. Chougar et al., « Automated Categorization of Parkinsonian Syndromes Using Magnetic Resonance Imaging in a Clinical Setting », Movement Disorders, vol. 36, n° 2, p. 460-470, févr. 2021, doi: [10.1002/mds.28348](https://doi.org/10.1002/mds.28348).
- [14] H. Huppertz et al., « Differentiation of neurodegenerative parkinsonian syndromes by volumetric magnetic resonance imaging analysis and support vector machine classification », Movement Disorders, vol. 31, n° 10, p. 1506-1517, oct. 2016, doi: [10.1002/mds.26715](https://doi.org/10.1002/mds.26715).
- [15] V. Vapnik, S. Golowich, et A. Smola, « Support Vector Method for Function Approximation, Regression Estimation and Signal Processing », in Advances in Neural Information Processing Systems, MIT Press, 1996. Consulté le: 15 mars 2026. [En ligne]. Disponible sur: [Votre texte de paragraphe](#)
- [16] A. Hammers et al., « Three-dimensional maximum probability atlas of the human brain, with particular reference to the temporal lobe », Human Brain Mapping, vol. 19, n° 4, p. 224-247, août 2003, doi: [10.1002/hbm.10123](https://doi.org/10.1002/hbm.10123).